

PRÉDISINISTRE: Détection de fraude sur des sinistres d'assurance

Présenté par: Christ Peryclais Ngolo & Souhaibou Seynou

Mentor: Nicolas Fradin

7 juillet 2026

CONTEXTE ET OBJECTIFS

Contexte

La fraude à l'assurance constitue un **enjeu économique majeur** pour les assureurs.

Le projet

Le projet porte sur la **détection de réclamations potentiellement frauduleuses**.

L'objectif 1

L'objectif principal est de **développer un modèle prédictif** capable d'identifier les dossiers suspects.

L'objectif 2

L'objectif complémentaire est d'**identifier les variables explicatives les plus pertinentes**.

JEU DE DONNÉES ET VARIABLE CIBLE

Jeu de données

- **Insurance_claims.csv**
- publié par ABDELRAHIM AQQAD le 22 août 2023 (Version 2) sur le site internet de Mendeley Data

Composition du jeu de données

- **1000 observations**
- **40 variables**

Variable cible

- **'*Fraud_reported*'**


Répartition

- **75,3% non-fraude**
- **24.7% fraude**

Métriques

- Le déséquilibre de classes justifie l'usage du **Recall**, du **F1-score** et du **ROC-AUC**

Distribution de la variable cible : fraud_reported



ANALYSE EXPLORATOIRE : POINTS CLÉS

Les variables les plus informatives

- les caractéristiques du sinistre
- les montants réclamés
- certaines variables contextuelles


la variable catégorielle la plus discriminante

• 'incident_severity'


Les signaux numériques importants.

• 'total_claim_amount' et 'vehicle_claim'

Matrice de corrélation (Pearson)
Variables numériques + variable cible Fraude



Distribution des variables numériques clés par statut de fraude



Variable	Chi2	ddl	p-value	Cramér V	Force
incident_severity	264.24	3	0.0000	0.514	FORTE
incident_type	29.13	3	0.0000	0.171	FAIBLE
insured_education_level	1.69	6	0.9460	0.041	NÉGLIGEABLE
authorities_contacted	8.28	3	0.0406	0.095	NÉGLIGEABLE

Les corrélations avec la cible

Les corrélations avec la cible restent faibles, ce qui suggère un signal surtout non linéaire

PRÉPARATION DES DONNÉES

Nettoyage
&
Encodage

Action	Justification
Suppression '_c39'	100 % de NaN
Suppression des identifiants	Cardinalité maximale → sur-apprentissage
Transformation des dates	Extraire les features temporelles utiles
Remplacement ? → NaN	Uniformiser les valeurs manquantes
Imputation 'authorities_contacted'	NaN = aucune autorité (logique métier)
Imputation 'collision_type', 'property_damage' et 'police_report_available'	Mode conditionnel à la cible
Correction 'umbrella_limit'	Valeur négative incohérente (-1 000 000) → valeur absolue
Encodage & Feature Engineering	Préparer pour le ML

Création de nouvelles
variables

Feature	Formule	Interprétation
'claim_ratio'	Total réclamé / Prime annuelle	Ratio élevé = réclamation suspecte
'injury_share'	Montant corporel / Total réclamé	Part corporelle surestimée
'vehicle_share'	Montant véhicule / Total réclamé	Part véhicule dans le sinistre
'is_high_deductable'	1 si franchise > 1 000 \$	Indicateur de risque aggravé
'policy_age_years'	Extraction de l'ancienneté de la police en année	L'ancienneté de la police en année
'incident_month'	Extraction du mois de l'incident	Le mois de l'incident
'incident_dayofweek'	Extraction du jour de la semaine	Le jour de la semaine de l'incident

Séparation des jeux de
données d'entraînement et
de test

— Partitionnement train/test —
Train : 800 obs. | Taux fraude : 24.75%
Test : 200 obs. | Taux fraude : 24.50%
Features : 144

BASELINE ET PROTOCOLE D'ÉVALUATION

Principe

- Les baselines servent de point de référence avant la modélisation avancée


Les modèles de bases testés

- DummyClassifier
- Régression Logistique
- Random Forest

Conclusion

- Les scores de cross-validation confirment les performances observées sur le jeu de test unique (pas de sur-apprentissage majeur).
- **Le Random Forest reste le meilleur modèle en termes d'AUC mais son rappel sur la classe fraude doit être amélioré**

Modèle	ROC-AUC	F1-Score	Analyse
DummyClassifier	~0.50	~0.00	Borne inférieure absolue
Régression Logistique	~0.786	~0.55	Bon équilibre précision/rappel
Random Forest	~0.845	~0.34	Meilleure AUC mais rappel fraude insuffisant



— Validation croisée 5-fold stratifiée (métrique : ROC-AUC) —

Régression Logistique : 0.8646 ± 0.0292

Scores par fold : [np.float64(0.8089), np.float64(0.8865), np.float64(0.8619), np.float64(0.8843), np.float64(0.8815)]

Random Forest : 0.9024 ± 0.0196

Scores par fold : [np.float64(0.8937), np.float64(0.889), np.float64(0.922), np.float64(0.8784), np.float64(0.929)]

MODÉLISATION AVANCÉE


Les
modèles
testés

- LogisticRegression
- RandomForest
- AdaBoost
- GradientBoosting
- HistGradientBoosting
- XGBoost

Processing
&
entraînement
des modèles


- Implémentation d'un **pipeline** intégrant tous les traitements et le modèle à tester
- Traitement du déséquilibre des classes dans le pipeline par '**class_weight**' et **SMOTE**
- Comparaison réalisée par **validation croisée stratifiée** à 5 plis

Déséquilibre des classes



Modèle	ROC-AUC	F1	Recall
LogisticRegression	0.5970±0.050	0.3846±0.036	0.5767±0.084
RandomForest	0.9126±0.016	0.6472±0.037	0.5556±0.060
AdaBoost	0.9209±0.018	0.7262±0.034	0.7022±0.074
GradientBoosting	0.9206±0.012	0.7394±0.042	0.7123±0.060
HistGradientBoosting	0.9182±0.018	0.7411±0.057	0.7276±0.079
XGBoost	0.9134±0.018	0.7540±0.052	0.7935±0.086

Comparaison des Pipelines (CV 5-fold sur X_train)



OPTIMISATION ET CHOIX DU MODÈLE FINAL

Optimisation des hyperparamètres des 3 meilleurs modèles: HistGradientBoosting, GradientBoosting et XGBoost

- Optimisation des hyperparamètres par **RandomizedSearchCV** et **GridSearchCV**, appliqués aux Pipelines intégrant les prétraitements
- une validation croisée stratifiée à 5 plis est utilisée, avec le ROC-AUC comme métrique d'optimisation


Modèle optimisé	ROC-AUC (CV)
HistGradientBoosting	0,9289
GradientBoosting	0,9261
XGBoost	0,9228

Evaluation sur test

Modèle	ROC-AUC (test)	F1-score (test)	Recall (test)
HistGradientBoosting	0,9099	0,6957	0,6531
GradientBoosting	0,8958	0,6517	0,5918
XGBoost	0,9090	0,7455	0,8367

Ajustement du seuil de décision du modèle XGBoost de 0,50 à 0,49

- Recall = 0,8571
- Précision = 0,6774
- F1-score = 0,7568



Choix du meilleur modèle

- Le modèle **XGBoost** est retenu comme modèle final, car il présente **le meilleur rappel (0.86), le meilleur F1-score (0.76) et le même ROC-AUC (0.91)** que le modèle HistGradientBoosting sur le jeu de test, critères prioritaires dans un contexte de détection de fraude.
- **XGBoost est retenu car il offre le meilleur compromis entre détection de fraude et robustesse.**
- **Le Recall est ici prioritaire car manquer une fraude est particulièrement coûteux.**

INTERPRÉTATION FINALE

1 Permutation importance des variables globales

- *incident_severity*
- *insured_hobbies*
- *property_damage*
- *collision_type*


2 Explication par perturbation locale

- *incident_severity*
- *property_damage*
- *collision_type*
- *insured_occupation*


3 Permutation importance des variables encodées

- *incident_severity_Major Damage*
- *property_damage_NO*
- *insured_hobbies_chess*
- *collision_type_Side Collision*


Permutation Importance (n=20) — XGBoost



2 Explications locales par perturbation (approx. SHAP)



- ## 3
- incident_severity_Major Damage
 - property_damage_NO
 - insured_hobbies_chess
 - collision_type_Side Collision
 - insured_hobbies_cross-fit
 - collision_type_Rear Collision
 - witnesses
 - vehicle_share
 - auto_year
 - incident_state_WV
 - policy_csl_250/500
 - bodily_injuries
 - incident_state_SC
 - policy_state_IL
 - umbrella_limit
 - insured_hobbies_yachting
 - claim_ratio
 - incident_month
 - insured_occupation_handlers-cleaners
 - authorities_contacted_Ambulance



CONCLUSION

Démarche complète	Le projet a permis de construire un pipeline complet de détection de fraude sur des sinistres d'assurance en suivant toutes les étapes de data science (Exploration, préparation, modélisation, interprétation et évaluation finale).
Un modèle optimisé et robuste	XGBoost optimise le compromis entre performance globale et détection de la classe minoritaire. L'ajustement du seuil améliore le rappel, critère clé en fraude. ROC-AUC = 0,909, F1-score = 0,757, Recall = 0,857.
L'interprétabilité métier	Les analyses d'interprétabilité renforcent la confiance dans le modèle, compréhensible et facilement utilisable par le métier. Le modèle est cohérent avec les objectifs métiers.
L'opérabilité du modèle	Le pipeline est sauvegardé et prêt pour un usage opérationnel futur et une intégration applicative.
Les perspectives d'amélioration	L'intégration de nouvelles sources de données. Un suivi des performances dans le temps. etc.